

Relatório de solução: previsão da temperatura final do banho

Steelproof, redução do consumo energético no forno-panela

Etapa 3 do Projeto Final. Bootcamp de Data Science, TripleTen. Autor: Fernando Szekut. Agosto de 2026.

Resumo

A Steelproof quer gastar menos energia elétrica no refino do aço. O consumo se concentra no forno-panela, onde o banho é reaquecido por arco elétrico até chegar à temperatura de lingotamento. Hoje essa temperatura é buscada por tentativa e erro: aquece-se, mede-se, e se faltou, aquece-se de novo. Cada iteração desnecessária é energia desperdiçada e tempo de forno ocupado.

Construí um modelo que prevê em que temperatura o banho vai terminar, a partir da condição inicial da corrida e do tratamento que se pretende aplicar. Ele responde a uma pergunta condicional: em que temperatura a corrida termina se eu aplicar este plano de aquecimento. É isso que permite comparar planos antes de gastar a energia, em vez de descobrir o resultado depois.

O modelo entrega erro médio absoluto (MAE, do inglês *mean absolute error*) de 5,22 °C em 488 corridas posteriores no tempo, que ele nunca viu. A meta que fixei no plano de trabalho era 6,8 °C, e o piso de referência, o que se acerta chutando sempre a média histórica, é 10,42 °C. O erro cai pela metade em relação a não ter modelo nenhum, e sete em cada dez corridas ficam dentro da tolerância.

O desperdício que isso permite cortar fica entre 2,8% e 5,6% da energia de arco por corrida no cenário que considero realista, o equivalente a deixar de aplicar de 0,13 a 0,26 ciclo de aquecimento em cada corrida, de um total médio de 4,6. Converter esse valor para reais depende de uma informação que os dados não trazem, e digo adiante qual é e como obtê-la.

O modelo não serve igualmente para todas as corridas, e essa é a informação mais útil do trabalho. As corridas em que ele erra muito são reconhecíveis antes de começarem, pelo volume de tratamento planejado, o que permite entregá-lo com uma regra de uso em vez de aplicá-lo às cegas.

O cenário

O que a Steelproof quer resolver

Reduzir o consumo de energia elétrica no processamento do aço. Na metalurgia de panela, o aço líquido chega do forno de fusão, recebe adições de liga e é reaquecido por eletrodos de grafite até a temperatura correta para o lingotamento. O reaquecimento por arco é o item pesado da conta de energia dessa etapa.

Por que isso custa caro hoje

A temperatura de destino é conhecida, porque a faixa de lingotamento é especificação. O que não se sabe é em que temperatura a corrida vai efetivamente terminar depois do tratamento aplicado. A incerteza está no resultado, não na meta.

No registro completo da planta, antes de qualquer filtro de qualidade, cada corrida recebe em média 4,6 ciclos de aquecimento e 4,0 medições de temperatura. O padrão descreve um processo iterativo: aquece, mede, avalia, repete. Duas fontes de desperdício saem daí.

A primeira é a margem de segurança. Sem saber onde a corrida vai parar, o caminho seguro é aquecer um pouco a mais. Aço frio no lingotamento causa problema imediato de qualidade, enquanto aço um pouco quente demais custa apenas energia. A assimetria empurra a operação para o lado caro, e a margem embutida é proporcional à incerteza sobre o resultado.

A segunda é a iteração. Cada ciclo extra de aquecimento tem custo energético, e cada medição extra consome um sensor descartável e interrompe o processo. Extrapolando o ritmo observado nos dados, 27 corridas por dia, a planta faz cerca de 9.850 corridas e 40 mil medições de temperatura por ano.

Por que vale resolver

Reduzir a incerteza sobre a temperatura final ataca as duas fontes ao mesmo tempo. Permite encolher a margem de segurança e permite dimensionar o aquecimento de uma vez, em vez de convergir por tentativas. Não se trata de aquecer menos do que o processo precisa. Trata-se de parar de pagar pela ignorância sobre onde ele vai terminar.

O critério de sucesso

No plano de trabalho da Etapa 1 fixei MAE de no máximo 6,8 °C como indicador-chave de desempenho (KPI, do inglês *key performance indicator*). O número não é arbitrário. Ele precisa ser bem menor que a dispersão natural do alvo para que a previsão carregue informação. A temperatura final tem desvio-padrão de apenas 15,9 °C, cerca de metade da dispersão da temperatura de entrada. Prever dentro de 6,8 °C significa acertar dentro de menos da metade de um desvio-padrão, o que torna o problema mais difícil do que a escala absoluta em graus sugere.

Desenvolvimento do projeto

Dados e qualidade iniciais

São sete arquivos, ligados pela coluna `key` , que identifica a corrida:

Fonte	Conteúdo	Granularidade
<code>data_arc</code>	potência ativa e reativa, início e fim de cada aquecimento	1 linha por ciclo
<code>data_temp</code>	medições de temperatura com horário	1 linha por medição
<code>data_gas</code>	volume de gás de purga	1 linha por corrida
<code>data_bulk</code> e <code>data_bulk_time</code>	massa e horário de 15 materiais a granel	1 linha por corrida
<code>data_wire</code> e <code>data_wire_time</code>	massa e horário de 9 materiais em arame	1 linha por corrida

Nenhuma linha duplicada. A contagem de corridas varia entre as fontes, 3.239 no gás, 3.216 na temperatura, 3.081 no arame, o que significa que o cruzamento gera ausências por falta de registro. Cada tipo de ausência precisa de tratamento próprio.

Encontrei cinco problemas de qualidade. O primeiro é uma potência reativa fisicamente impossível, um registro de menos 715,5 contra mediana de 0,42, três ordens de grandeza fora da faixa e com sinal invertido. Marquei como ausente, e não como zero, porque zero afirmaria que não houve potência reativa quando o que se sabe é apenas que a leitura não serve.

O segundo são as corridas sem duas medições de temperatura. O alvo é a última temperatura registrada e o atributo de entrada é a primeira, de modo que corridas com uma única medição não permitem separar entrada de saída. Sobraram 2.475 das 3.216.

O terceiro é a mudança de protocolo em 06/08/2019. A partir dessa data o registro passa de múltiplas medições por corrida para uma só. O padrão é compatível com alteração no procedimento de gravação e não com falha de sensor, porque falha produziria ausência ou valor inválido, não uma mudança sistemática de formato. Cortei o período posterior.

O quarto são as durações de tratamento fora da faixa operacional, com máximo de 395 minutos contra mediana de 31. Cortei fora do intervalo de 1 a 100,6 minutos, com lastro no processo: tratamento muito longo implica troca de calor com o refratário que descaracteriza a corrida.

O quinto são quatro temperaturas iniciais impossíveis, entre 1.191 e 1.227 °C contra mínimo operacional de 1.519 °C. Não as removi por serem estatisticamente atípicas, e sim porque as duas leituras da corrida são mutuamente incompatíveis. Elas implicariam elevação de 365 a 408 °C consumindo de 0,6% a 3,8% da energia que a planta gasta para isso. Não importa qual das duas leituras está errada, porque o par não pode estar certo.

A limpeza custou 24% das corridas, quase todas pelo segundo item.

Proteção contra vazamento de informação

A armadilha central deste problema é o vazamento de informação. Se qualquer medição intermediária de temperatura entrar como atributo, o erro despenca artificialmente e o modelo fica inútil na prática, porque no momento em que se quer usá-lo essas medições ainda não existem.

Admiti como atributo apenas a primeira medição de cada corrida. O alvo é a última. Os timestamps e a chave `key` ficaram fora dos atributos, para que o modelo não decore a posição da corrida na série de produção. Padronizei a escala dentro de um `Pipeline` reajustado a cada dobra da validação, de modo que nem a média usada na normalização vaze do futuro para o passado.

Divisão entre treino e teste

Usei corte cronológico de 80/20, com as 1.950 primeiras corridas para treino e as 488 seguintes para teste. A separação é posicional: ordenei as corridas pelo horário da primeira medição e cortei na posição 1.950. Nenhuma corrida aparece nos dois conjuntos.

O corte cai dentro do dia 19/07, que por isso tem corridas dos dois lados, 8 no treino e 13 no teste. A última corrida de treino começa às 8h09 e a primeira de teste às 9h06, de forma que a ordem temporal é respeitada mesmo dentro do dia da fronteira. O treino cobre de 03/05 a 19/07 e o teste de 19/07 a 05/08.

Amostragem aleatória seria mais generosa e menos honesta, porque com ordem temporal embaralhar permite que o modelo aprenda com corridas posteriores às que está avaliando.

Testei antes se havia deriva no alvo ao longo do período, e não há: as médias mensais ficam entre 1.594 e 1.597 °C. O corte cronológico não é necessário por instabilidade dos dados. Ele é necessário porque simula a condição real de uso, em que só se conhece o passado.

Colinearidade

As variáveis energéticas medem a mesma coisa por caminhos diferentes, e o diagnóstico pelo fator de inflação da variância (VIF, do inglês *variance inflation factor*) confirma:

Atributo	VIF
tempo de arco	37,9
potência ativa	29,2
potência reativa	16,2
energia	11,9

Acima de 10 já é colinearidade grave. Numa regressão comum isso torna os coeficientes instáveis a ponto de inverter sinal, e o modelo poderia concluir que mais arco esfria o aço. Foi por isso que usei Ridge no lugar da regressão linear pura, porque a penalização estabiliza os coeficientes sob colinearidade. Modelos de árvore não sofrem do problema.

Modelos avaliados

Avaliei quatro famílias, mais o piso de referência, todas com busca de hiperparâmetros em validação cruzada temporal. O `DummyRegressor` na média serve de piso, ou seja, o que se acerta sem modelo algum. O Ridge é a referência linear, com a colinearidade sob controle. O Random Forest captura interações não lineares. O LightGBM aplica boosting regularizado. O CatBoost entrou por causa da esparsidade das colunas de adição, já que 22 das 34 ficam em zero na maioria das corridas.


Resultados

Desempenho comparado

Todos os números abaixo estão medidos nas 488 corridas de teste, posteriores no tempo. RMSE é a raiz do erro quadrático médio e R² o coeficiente de determinação:

Modelo	MAE treino	MAE teste	RMSE	R ²	Redução do erro vs. piso	Atinge meta
Dummy (média)	10,19	10,42	15,56	-0,02		não
Ridge	6,05	6,72	9,38	0,63	35,5%	sim
Random Forest	3,14	5,63	7,47	0,77	45,9%	sim
CatBoost	4,76	5,42	7,14	0,79	48,0%	sim
LightGBM	3,73	5,30	7,09	0,79	49,2%	sim
LightGBM calibrado		5,22	7,09	0,79	49,9%	sim

Há uma observação metodológica que faz diferença no número relatado. No plano de trabalho eu havia estimado o piso em 12,8 °C. Medido nos dados limpos, ele é 10,42 °C. Calculei a redução contra o valor medido. Manter a estimativa do plano teria inflado o resultado relatado de 49,9% para 59,2% sem que uma única linha do modelo mudasse.



O erro cai de 10,42 °C sem modelo para 5,22 °C com o LightGBM calibrado, abaixo da meta de 6,8 °C.

Seleção do modelo final

Escolhi o LightGBM com calibração de viés. A diferença de MAE para o CatBoost é de 0,12 °C, abaixo do limiar de 0,3 °C que eu havia fixado no plano como diferença relevante. Quando o erro não desempata, o critério passa a ser outro, e comparei então a importância dos atributos das duas famílias. Elas apontam os mesmos atributos, na mesma ordem, o que indica que ambas capturam física do processo e não idiossincrasia do algoritmo. Fiquei com o LightGBM pelo erro marginalmente menor, e registro o CatBoost como alternativa equivalente.

A calibração de viés é um ajuste barato e de efeito real. O modelo bruto subestimava a temperatura em 1,26 °C de forma sistemática. Estimei esse deslocamento nos últimos 10% do treino, uma faixa separada que não é o teste, e o descontei. O viés cai para 0,25 °C, o MAE de 5,30 para 5,22 °C, e a fração de corridas dentro da tolerância sobe de 70,5% para 72,1%, sem nenhuma complexidade adicional no modelo.

O que o modelo aprendeu


Medi a importância por permutação no conjunto de teste, método que não favorece atributos de alta cardinalidade como faria a importância interna das árvores:

Atributo	Importância (°C de MAE)
temperatura inicial	6,12
potência ativa total	2,72
massa total de arame	1,32
energia	1,15
duração total do arco	0,76
adições específicas (arame 1, granel 6)	0,33 e 0,30
intervalo desde a corrida anterior	0,05

A leitura é fisicamente coerente. Onde o banho começa domina, seguido do quanto de energia elétrica foi aplicada e das adições que consomem calor para se dissolver. Os resíduos não mostram padrão contra a temperatura inicial, o que indica que não sobrou sinal óbvio na mesa.

Uma hipótese minha não se sustentou. Eu havia proposto o intervalo desde a corrida anterior como proxy do estado térmico do refratário, supondo que panela recém-usada estaria mais quente e roubaria menos calor do banho. A importância ficou em 0,05 °C, praticamente zero. Registro o resultado como ele saiu, porque a hipótese era razoável e os dados não a confirmaram.

Onde o erro cai, por faixa de erro absoluto



Sete em cada dez corridas ficam dentro da tolerância; a cauda acima de 10 °C responde por 12,9%.

Onde o modelo erra, e por que isso é útil

Dizer que 72% das corridas ficam dentro da tolerância deixa 28% de fora, e errar 7 °C é diferente de errar 25 °C. Por isso quebrei o erro em faixas:

Faixa de erro	% das corridas de teste
até 3 °C	38,5%
3 a 6,8 °C	33,6%
6,8 a 10 °C	15,0%
10 a 20 °C	10,9%
acima de 20 °C	2,0%

O erro mediano é de 3,97 °C, o percentil 90 fica em 11,13 °C e o máximo em 30,10 °C.

A cauda é o que limita o uso. Cerca de uma corrida em cada oito, 12,9%, erra mais de 10 °C, e nessas a estimativa não substitui a medição. A pergunta prática é se dá para reconhecer essas corridas antes de rodá-las, e a resposta é sim:


	Corridas com erro > 10 °C	Demais	Diferença
temperatura inicial	1.596,1 °C	1.586,3 °C	+0,6%
energia total	0,26	0,19	+38,7%
duração do arco	36,8 min	28,9 min	+27,5%
potência ativa somada	3,70	2,98	+24,3%

As corridas ruins não se distinguem pela temperatura de entrada, que é praticamente igual à das demais. Elas se distinguem pelo volume de tratamento, e são as corridas longas e pesadas.

A leitura física é direta. Quanto mais longo o tratamento, mais tempo o banho troca calor com o refratário, com o ambiente e com as adições, e mais o resultado depende de fatores que não estão nos dados. O modelo é confiável no regime normal de operação e perde precisão exatamente onde o processo se afasta dele.

A consequência prática é o motivo de eu ter feito esta análise. O que separa as corridas ruins não é a temperatura de entrada, que ninguém escolhe, e sim o volume de tratamento, que é decidido antes de a corrida começar. Um plano que prevê muita energia e arco longo já sinaliza que ali a estimativa merece confirmação por medição.

Registro o limite dessa leitura. As diferenças acima estão medidas sobre energia e arco realizados, porque é o que os arquivos trazem. Transpor a regra para o plano supõe que o planejado se aproxima do executado, o que é razoável para dimensionamento mas não consigo verificar com estes dados.



A temperatura de entrada quase não distingue as corridas ruins; o volume de tratamento sim, e ele é decidido antes da corrida.

Estimativa de impacto no negócio

A coluna `Active power` não tem unidade documentada. Tentei calibrá-la pela física, comparando a energia registrada com a elevação de temperatura obtida, e a massa implicada não bate com a capacidade de 100 t informada sob nenhuma hipótese razoável de rendimento. Isso não invalida o modelo, porque ele aprende a relação

entre a grandeza registrada e a temperatura seja qual for a escala dela, mas invalida qualquer conversão direta para megawatt-hora ou para reais.

Apresento então o impacto em três camadas, da mais firme para a mais dependente de informação externa: a grandeza física adimensional, que os dados sustentam por inteiro; a tradução para unidades operacionais que a planta reconhece; e a fórmula pronta para a conversão financeira, faltando um único parâmetro que só a planta tem.

Mecanismo da redução

Sem modelo, a incerteza sobre em que temperatura a corrida vai terminar é de 10,42 °C. Com o modelo, é de 5,22 °C. A margem de segurança térmica pode encolher em até 5,20 °C, e essa é a grandeza que o projeto entrega.

Converter graus em energia exige saber quanto a planta gasta por grau na margem, e não em média, porque são coisas diferentes. A energia de uma corrida paga duas contas ao mesmo tempo: elevar a temperatura do banho e repor o calor que ele perde para o refratário, para o ambiente e para as adições enquanto é tratado. A segunda parcela não desaparece quando se mira dois graus mais baixo. Dividir energia total por elevação obtida misturaria as duas contas e superestimaria a economia.

Separei-as regredindo a energia de cada corrida contra a elevação obtida e a duração do tratamento. A elevação responde por 0,00429 unidades de energia por grau, e a duração por 0,00439 unidades por minuto, com R² de 0,64. É o primeiro coeficiente que interessa aqui, porque é ele que mede o que se deixa de gastar ao mirar mais baixo:

Cenário	Margem reduzida	Energia poupada por corrida	% da energia de arco	Ciclos evitados
Conservador, captura 1/4 da margem	1,30 °C	0,0056	2,8%	0,13
Central, captura metade	2,60 °C	0,0112	5,6%	0,26
Teto, captura a margem inteira	5,20 °C	0,0223	11,3%	0,52

A hipótese que separa os cenários é quanto da margem de segurança a operação de fato consegue liberar. O teto supõe que hoje se sobreaquece exatamente o equivalente à incerteza, o que é agressivo, porque parte da margem existente responde a fatores que o modelo não elimina. Considero o cenário conservador o piso defensável e o central a expectativa realista.

Duas ressalvas sobre a estimativa do coeficiente. Ela é observacional: a energia aplicada causa a elevação e a duração é escolhida pelo operador, de modo que o número não é uma medida causal limpa. E ela não é constante ao longo da faixa, variando por fator de 2,7 entre as corridas que menos e as que mais aquecem, o que significa que a tabela vale para o regime médio de operação e perde validade nos extremos.

Impacto em unidades operacionais

Um ciclo de aquecimento consome em média 0,0428 unidades de energia. Nessa escala, o cenário conservador equivale a deixar de aplicar 0,13 ciclo por corrida, cerca de 1.280 ciclos por ano no ritmo de 9.850 corridas anu-

ais. O cenário central equivale a 0,26 ciclo por corrida, cerca de 2.570 ciclos por ano, ou 5,6% de toda a energia de arco da planta.

Há um efeito paralelo que não entra nessa conta e é mais fácil de auditar, que são as medições de temperatura. A planta faz cerca de 40 mil por ano, cada uma consumindo um sensor descartável e interrompendo o processo. Um modelo que acerta dentro de 3 °C em 38,5% das corridas e dentro de 6,8 °C em 72% permite reduzir a frequência de medição de confirmação nas corridas do regime normal, mantendo-a integral nas 13% de cauda que a regra da seção anterior identifica de antemão.

A conversão financeira

Falta um único número, e ele não está nos dados:

```
Economia anual (R$) = 9.850 corridas × 0,0056 a 0,0112 unidades de energia por corrida  
× [ R$ por unidade de "Active power" ]
```

Traduzindo: a economia anual fica entre 55 e 110 unidades de energia, na escala em que a coluna **Active power** é registrada. Assim que a planta informar o que essa coluna mede, e o custo do megawatt-hora que ela pratica, a conta fecha em reais em uma linha.

Registro isso como pergunta a fazer, não como número a estimar. Chutar um fator de conversão produziria um valor bonito e indefensável.


Efeitos não energéticos

Há três efeitos que vale citar sem quantificar, porque quantificá-los exigiria dados que não estão aqui.

Deixar de aplicar de 0,13 a 0,26 ciclo por corrida libera capacidade do forno-panela. Se o forno for gargalo da linha, esse efeito pode superar o de energia. Se não for, ele não se materializa. Depende do arranjo da planta, que eu não conheço.

Reduzir a variabilidade da temperatura de entrega também deve reduzir a incidência de corridas fora da faixa de lingotamento, e portanto o retrabalho. Não consigo medir isso, porque os dados não trazem descarte nem qualquer indicador de qualidade.

Menos tempo de arco significa ainda menos consumo de eletrodo de grafite e menos agressão térmica ao revestimento refratário. O efeito vai na mesma direção da economia de energia, mas não tenho base nos dados para dimensioná-lo.



Cenários de economia conforme quanto da margem de segurança a operação consiga liberar.

O que o modelo não sabe

Entrego esta seção junto com o resultado porque um MAE dentro da meta é fácil de ler como problema resolvido, e não é o caso.

Começo pelo que é o inverso dos demais: em parte das corridas o modelo sabe demais. As variáveis de processo agregam a corrida inteira, mas nem sempre a última medição de temperatura é o último evento. Em 135 corridas, 5,5% do total, há aquecimento ou adição posteriores ao instante do alvo. Nessas, a energia somada carrega informação que ainda não existia quando a previsão seria feita. O MAE de 5,22 °C está provavelmente um pouco otimista por causa disso. O caminho correto é fixar o instante da previsão e agregar apenas o que ocorreu antes dele, e é o primeiro item que eu refaria.

O modelo não vê a composição química da corrida. Ligas diferentes têm calor específico diferente, e nada nos sete arquivos identifica qual liga está sendo produzida. Parte do erro residual quase certamente vem daí, e nenhum ajuste de hiperparâmetro alcança essa informação.

O modelo não vê o estado do refratário, a temperatura ambiente, o desgaste dos eletrodos nem a panela específica de cada corrida. A única proxy disponível foi testada e não funcionou.

O período coberto é de três meses. Não encontrei deriva dentro dessa janela, mas três meses não garantem estabilidade ao longo de um ano.

O formato de gravação mudou em 06/08/2019. Se ele continuar como ficou, dados novos chegam com uma única medição por corrida e não servem nem para treinar nem para validar o modelo.

Conclusões e recomendações

O que está entregue é um modelo que prevê a temperatura final do banho com erro médio de 5,22 °C, contra 10,42 °C de não ter modelo nenhum. A meta de 6,8 °C foi atingida com folga, 72% das corridas ficam dentro da tolerância, e a avaliação foi feita em corridas posteriores no tempo que o modelo nunca viu. Junto com ele vai uma regra que diz onde confiar nele e onde não confiar.

Deixo cinco recomendações, em ordem de retorno sobre esforço.

A primeira é adotar o modelo com regra de uso diferenciada, e não como número único. Nas corridas do regime normal, com plano de tratamento dentro da faixa usual de energia e arco, a previsão dimensiona o aquecimento e reduz a medição de confirmação. Nas corridas de tratamento longo e pesado, que os dados mostram serem cerca de 13% e que são identificáveis pelo plano, o modelo entra como orientação e a medição continua obrigatória. É a recomendação de maior valor imediato e não exige nenhum dado novo.

A segunda é informar o que a coluna `Active power` mede. É a única pendência entre a economia física já demonstrada e a economia em reais. Uma resposta da engenharia da planta resolve, e sem ela nenhuma estimativa financeira deste projeto se sustenta.

A terceira é restabelecer o registro de múltiplas medições de temperatura por corrida. O protocolo mudou em 06/08/2019 e, se permanecer assim, o modelo não pode ser retreinado nem revalidado com dados novos. É decisão da fábrica, não do modelo, e sem ela o projeto tem prazo de validade.

A quarta é refazer o recorte temporal dos atributos antes de tratar 5,22 °C como número final. Agregaria apenas operações anteriores ao instante da previsão e mediria o resultado em um bloco de tempo ainda não utilizado, porque este conjunto de teste também serviu para escolher entre as quatro famílias de modelo, de modo que o número atual tem um grau a menos de independência do que o ideal.

A quinta é registrar a liga produzida em cada corrida. É a informação ausente com maior potencial de reduzir o erro residual. Não altera nada no que já foi entregue, mas define o teto de uma versão futura.

Fecho com uma ressalva. O objetivo que declarei na Etapa 1, dimensionar o aquecimento em vez de buscá-lo por tentativa e erro, é alcançável com o que está aqui, desde que o modelo seja lido como comparação entre planos de tratamento e não como previsão passiva de uma corrida parada na entrada. É essa leitura condicional que transforma uma estimativa de temperatura em decisão de quanta energia aplicar, e é dela que vem a economia.