

Relatório de solução: previsão da temperatura final do banho

Steelproof, redução do consumo energético no forno-panela

Etapa 3 do Projeto Final. Bootcamp de Data Science, TripleTen. Autor: Fernando Szekut. Agosto de 2026.
Código, notebooks e o Markdown que gera este documento: github.com/FSzekut/steelproof

Resumo

A Steelproof quer gastar menos energia elétrica no refino do aço. O consumo se concentra no forno-panela, onde o banho é reaquecido por arco elétrico até chegar à temperatura de lingotamento. Hoje essa temperatura é buscada por tentativa e erro: aquece-se, mede-se, e se faltou, aquece-se de novo. Cada iteração desnecessária é energia desperdiçada e tempo de forno ocupado.

Construí um modelo que prevê em que temperatura o banho vai terminar, a partir da condição inicial da corrida e do tratamento que se pretende aplicar. Ele responde a uma pergunta condicional: em que temperatura a corrida termina se eu aplicar este plano de aquecimento. É isso que permite comparar planos antes de gastar a energia, em vez de descobrir o resultado depois.

O modelo entrega erro médio absoluto (MAE, do inglês *mean absolute error*) de 5,22 °C em 488 corridas posteriores no tempo, que ele nunca viu. A meta que fixei no plano de trabalho era 6,8 °C, e o piso de referência, o que se acerta chutando sempre a média histórica, é 10,42 °C. O erro cai pela metade em relação a não ter modelo nenhum, e sete em cada dez corridas ficam dentro da tolerância.

O desperdício que isso permite cortar fica entre 2,8% e 5,6% da energia de arco por corrida no cenário que considero realista, o equivalente a deixar de aplicar de 0,13 a 0,26 ciclo de aquecimento em cada corrida, de um total médio de 4,6. Converter esse valor para reais depende de uma informação que os dados não trazem, e digo adiante qual é e como obtê-la.

O modelo não serve igualmente para todas as corridas, e essa é a informação mais útil do trabalho. As corridas em que ele erra muito são reconhecíveis antes de começarem, pelo volume de tratamento planejado, o que permite entregá-lo com uma regra de uso em vez de aplicá-lo às cegas.

O cenário

O que a Steelproof quer resolver

Reduzir o consumo de energia elétrica no processamento do aço. Na metalurgia de panela, o aço líquido chega do forno de fusão, recebe adições de liga e é reaquecido por eletrodos de grafite até a temperatura correta para o lingotamento. O reaquecimento por arco é o item pesado da conta de energia dessa etapa.

Por que isso custa caro hoje

A temperatura de destino é conhecida, porque a faixa de lingotamento é especificação. O que não se sabe é em que temperatura a corrida vai efetivamente terminar depois do tratamento aplicado. A incerteza está no resultado, não na meta.

No registro completo da planta, antes de qualquer filtro de qualidade, cada corrida recebe em média 4,6 ciclos de aquecimento e 4,0 medições de temperatura. O padrão descreve um processo iterativo: aquece, mede, avalia, repete. Duas fontes de desperdício saem daí.

A primeira é a margem de segurança. Sem saber onde a corrida vai parar, o caminho seguro é aquecer um pouco a mais. Aço frio no lingotamento causa problema imediato de qualidade, enquanto aço um pouco quente demais custa apenas energia. A assimetria empurra a operação para o lado caro, e a margem embutida é proporcional à incerteza sobre o resultado.

A segunda é a iteração. Cada ciclo extra de aquecimento tem custo energético, e cada medição extra consome um sensor descartável e interrompe o processo. Extrapolando o ritmo observado nos dados, 27 corridas por dia, a planta faz cerca de 9.850 corridas e 40 mil medições de temperatura por ano.

Por que vale resolver

Reduzir a incerteza sobre a temperatura final ataca as duas fontes ao mesmo tempo. Permite encolher a margem de segurança e permite dimensionar o aquecimento de uma vez, em vez de convergir por tentativas. Não se trata de aquecer menos do que o processo precisa. Trata-se de parar de pagar pela ignorância sobre onde ele vai terminar.

O critério de sucesso

No plano de trabalho da Etapa 1 fixei MAE de no máximo 6,8 °C como indicador-chave de desempenho (KPI, do inglês *key performance indicator*). O número não é arbitrário. Ele precisa ser bem menor que a dispersão natural do alvo para que a previsão carregue informação. A temperatura final tem desvio-padrão de apenas 15,9 °C, cerca de metade da dispersão da temperatura de entrada. Prever dentro de 6,8 °C significa acertar dentro de menos da metade de um desvio-padrão, o que torna o problema mais difícil do que a escala absoluta em graus sugere.

Desenvolvimento do projeto

Dados e qualidade iniciais

São sete arquivos, ligados pela coluna `key`, que identifica a corrida:

Fonte	Conteúdo	Granularidade
<code>data_arc</code>	potência ativa e reativa, início e fim de cada aquecimento	1 linha por ciclo
<code>data_temp</code>	medições de temperatura com horário	1 linha por medição
<code>data_gas</code>	volume de gás de purga	1 linha por corrida
<code>data_bulk</code> e <code>data_bulk_time</code>	massa e horário de 15 materiais a granel	1 linha por corrida
<code>data_wire</code> e <code>data_wire_time</code>	massa e horário de 9 materiais em arame	1 linha por corrida

Nenhuma linha duplicada. A contagem de corridas varia entre as fontes, 3.239 no gás, 3.216 na temperatura, 3.081 no arame, o que significa que o cruzamento gera ausências por falta de registro. Cada tipo de ausência precisa de tratamento próprio.

Encontrei cinco problemas de qualidade. O primeiro é uma potência reativa fisicamente impossível, um registro de menos 715,5 contra mediana de 0,42, três ordens de grandeza fora da faixa e com sinal invertido. Marquei como ausente, e não como zero, porque zero afirmaria que não houve potência reativa quando o que se sabe é apenas que a leitura não serve.

O segundo são as corridas sem duas medições de temperatura. O alvo é a última temperatura registrada e o atributo de entrada é a primeira, de modo que corridas com uma única medição não permitem separar entrada de saída. Sobraram 2.475 das 3.216.

O terceiro é a mudança de protocolo em 06/08/2019. A partir dessa data o registro passa de múltiplas medições por corrida para uma só. O padrão é compatível com alteração no procedimento de gravação e não com falha de sensor, porque falha produziria ausência ou valor inválido, não uma mudança sistemática de formato. Cortei o período posterior.

O quarto são as durações de tratamento fora da faixa operacional, com máximo de 395 minutos contra mediana de 31. Cortei fora do intervalo de 1 a 100,6 minutos, com lastro no processo: tratamento muito longo implica troca de calor com o refratário que descaracteriza a corrida.

O quinto são quatro temperaturas iniciais impossíveis, entre 1.191 e 1.227 °C contra mínimo operacional de 1.519 °C. Não as removi por serem estatisticamente atípicas, e sim porque as duas leituras da corrida são mutuamente incompatíveis. Elas implicariam elevação de 365 a 408 °C consumindo de 0,6% a 3,8% da energia que a planta gasta para isso. Não importa qual das duas leituras está errada, porque o par não pode estar certo.

A limpeza custou 24% das corridas, quase todas pelo segundo item.

Proteção contra vazamento de informação

A armadilha central deste problema é o vazamento de informação. Se qualquer medição intermediária de temperatura entrar como atributo, o erro despenca artificialmente e o modelo fica inútil na prática, porque no momento em que se quer usá-lo essas medições ainda não existem.

Admiti como atributo apenas a primeira medição de cada corrida. O alvo é a última. Os timestamps e a chave `key` ficaram fora dos atributos, para que o modelo não decore a posição da corrida na série de produção. Padronizei a escala dentro de um `Pipeline` reajustado a cada dobra da validação, de modo que nem a média usada na normalização vaze do futuro para o passado.

Divisão entre treino e teste

Usei corte cronológico de 80/20, com as 1.950 primeiras corridas para treino e as 488 seguintes para teste. A separação é posicional: ordenei as corridas pelo horário da primeira medição e cortei na posição 1.950. Nenhuma corrida aparece nos dois conjuntos.

O corte cai dentro do dia 19/07, que por isso tem corridas dos dois lados, 8 no treino e 13 no teste. A última corrida de treino começa às 8h09 e a primeira de teste às 9h06, de forma que a ordem temporal é respeitada mesmo dentro do dia da fronteira. O treino cobre de 03/05 a 19/07 e o teste de 19/07 a 05/08.

Amostragem aleatória seria mais generosa e menos honesta, porque com ordem temporal embaralhar permite que o modelo aprenda com corridas posteriores às que está avaliando.

Testei antes se havia deriva no alvo ao longo do período, e não há: as médias mensais ficam entre 1.594 e 1.597 °C. O corte cronológico não é necessário por instabilidade dos dados. Ele é necessário porque simula a condição real de uso, em que só se conhece o passado.

Colinearidade

As variáveis energéticas medem a mesma coisa por caminhos diferentes, e o diagnóstico pelo fator de inflação da variância (VIF, do inglês *variance inflation factor*) confirma:

Atributo	VIF
tempo de arco	37,9
potência ativa	29,2
potência reativa	16,2
energia	11,9

Acima de 10 já é colinearidade grave. Numa regressão comum isso torna os coeficientes instáveis a ponto de inverter sinal, e o modelo poderia concluir que mais arco esfria o aço. Foi por isso que usei Ridge no lugar da regressão linear pura, porque a penalização estabiliza os coeficientes sob colinearidade. Modelos de árvore não sofrem do problema.

Modelos avaliados

Avaliei quatro famílias, mais o piso de referência, todas com busca de hiperparâmetros em validação cruzada temporal. O `DummyRegressor` na média serve de piso, ou seja, o que se acerta sem modelo algum. O Ridge é a referência linear, com a colinearidade sob controle. O Random Forest captura interações não lineares. O LightGBM aplica boosting regularizado. O CatBoost entrou por causa da esparsidade das colunas de adição, já que 22 das 34 ficam em zero na maioria das corridas.

Hiperparâmetros

A busca é a mesma para todos: validação cruzada temporal com `TimeSeriesSplit` de 5 dobras, sempre sobre o treino, métrica MAE, semente 42. A partição temporal importa aqui mais que o de costume, porque o teste são as 488 corridas posteriores no tempo: validar embaralhando deixaria o modelo treinar em corridas futuras para prever passadas, e o número de validação sairia otimista.

O Ridge tem um só parâmetro, então varri a grade inteira com `GridSearchCV`, 25 valores de `alpha` em escala logarítmica de 10^{-3} a 10^3 . Nos três modelos de árvore o produto das grades passa de uma centena de combinações, e usei `RandomizedSearchCV` com orçamento fixo de sorteios.

Modelo	Espaço buscado	Sorteios	Escolhido	MAE na validação
Ridge	<code>alpha</code> : 25 valores, 10^{-3} a 10^3	grade inteira	<code>alpha</code> 3,1623	6,34 °C
Random Forest	<code>max_depth</code> 3–12 ou livre; <code>min_samples_leaf</code> 1–20; <code>max_features</code> sqrt/log2/0,3/0,6/1,0	15	<code>max_depth</code> 12; <code>min_samples_leaf</code> 2; <code>max_features</code> 1,0	6,32 °C
LightGBM	<code>num_leaves</code> 7–63; <code>learning_rate</code> 0,01–0,1; <code>min_child_samples</code> 5–40; <code>subsample</code> 0,7–1,0; <code>colsample_bytree</code> 0,6–1,0	20	<code>num_leaves</code> 31; <code>learning_rate</code> 0,01; <code>min_child_samples</code> 10; <code>subsample</code> 0,7; <code>colsample_bytree</code> 1,0	6,01 °C
CatBoost	<code>depth</code> 4–10; <code>learning_rate</code> 0,01–0,1; <code>l2_leaf_reg</code> 1–10	15	<code>depth</code> 4; <code>learning_rate</code> 0,03; <code>l2_leaf_reg</code> 3	5,96 °C

Três decisões dentro dessas grades não são padrão e valem a explicação.

O número de árvores não foi buscado. Fixei 400 no LightGBM e 500 iterações no CatBoost, em vez de deixar a parada antecipada escolher. A parada antecipada precisa de uma faixa de validação monitorada a cada iteração, e dentro de uma busca com `TimeSeriesSplit` essa faixa teria de sair de dentro de cada dobra — encurtando justamente as primeiras, que já são as menores. Prefiri fixar o teto e deixar o controle do sobreajuste com os parâmetros que o exercem de forma mais direta: `num_leaves`, `min_child_samples` e `subsample`.

`subsample_freq` está fixo em 1 na grade do LightGBM. Sem esse parâmetro o LightGBM ignora `subsample` em silêncio, sem erro nem aviso. A busca varreria cinco valores de subamostragem que não teriam efeito nenhum, e eu concluiria que o parâmetro não importa.

A busca de hiperparâmetros e o modelo não paralelizam ao mesmo tempo. O paralelismo fica dentro do estimador e a busca roda sequencial. Ativar os dois aninha processos e, com as bibliotecas que usam OpenMP, trava em vez de acelerar.

Vale registrar uma tensão nos números acima: na validação cruzada o CatBoost termina à frente, por 0,05 °C, e no teste a ordem se inverte. As duas diferenças estão abaixo do limiar de 0,3 °C que eu havia fixado no plano como relevante, o que é a própria razão de o desempate ter ido para outro critério — tratado adiante, em *Seleção do modelo final*.

Os valores desta seção são os que o notebook da Etapa 2 imprime ao executar, e reproduzem com a semente fixada.

Resultados


Desempenho comparado

Todos os números abaixo estão medidos nas 488 corridas de teste, posteriores no tempo. RMSE é a raiz do erro quadrático médio e R² o coeficiente de determinação:

Modelo	MAE treino	MAE teste	RMSE	R ²	Redução do erro vs. piso	Atinge meta
Dummy (média)	10,19	10,42	15,56	-0,02		não
Ridge	6,05	6,72	9,38	0,63	35,5%	sim
Random Forest	3,14	5,63	7,47	0,77	45,9%	sim
CatBoost	4,76	5,42	7,14	0,79	48,0%	sim
LightGBM	3,73	5,30	7,09	0,79	49,2%	sim
LightGBM calibrado		5,22	7,09	0,79	49,9%	sim

Há uma observação metodológica que faz diferença no número relatado. No plano de trabalho eu havia estimado o piso em 12,8 °C. Medido nos dados limpos, ele é 10,42 °C. Calculei a redução contra o valor medido. Manter a estimativa do plano teria inflado o resultado relatado de 49,9% para 59,2% sem que uma única linha do modelo mudasse.

Seleção do modelo final



O erro cai de 10,42 °C sem modelo para 5,22 °C com o LightGBM calibrado, abaixo da meta de 6,8 °C.

Escolhi o LightGBM com calibração de viés. A diferença de MAE para o CatBoost é de 0,12 °C, abaixo do limiar de 0,3 °C que eu havia fixado no plano como diferença relevante. Quando o erro não desempata, o critério passa a ser outro, e comparei então a importância dos atributos das duas famílias. Elas apontam os mesmos atributos, na mesma ordem, o que indica que ambas capturam física do processo e não idiosincrasia do algoritmo. Fiquei com o LightGBM pelo erro marginalmente menor, e registro o CatBoost como alternativa equivalente.

A calibração de viés é um ajuste barato e de efeito real. O modelo bruto subestimava a temperatura em 1,26 °C de forma sistemática. Estimei esse deslocamento nos últimos 10% do treino, uma faixa separada que não é o teste, e o descontei. O viés cai para 0,25 °C, o MAE de 5,30 para 5,22 °C, e a fração de corridas dentro da tolerância sobe de 70,5% para 72,1%, sem nenhuma complexidade adicional no modelo.

O que o modelo aprendeu

Medi a importância por permutação no conjunto de teste, método que não favorece atributos de alta cardinalidade como faria a importância interna das árvores:


Atributo	Importância (°C de MAE)
temperatura inicial	6,12
potência ativa total	2,72
massa total de arame	1,32
energia	1,15
duração total do arco	0,76
adições específicas (arame 1, granel 6)	0,33 e 0,30
intervalo desde a corrida anterior	0,05

A leitura é fisicamente coerente. Onde o banho começa domina, seguido do quanto de energia elétrica foi aplicada e das adições que consomem calor para se dissolver. Os resíduos não mostram padrão contra a temperatura inicial, o que indica que não sobrou sinal óbvio na mesa.

Uma hipótese minha não se sustentou. Eu havia proposto o intervalo desde a corrida anterior como proxy do estado térmico do refratário, supondo que panela recém-usada estaria mais quente e roubaria menos calor do banho. A importância ficou em 0,05 °C, praticamente zero. Registro o resultado como ele saiu, porque a hipótese era razoável e os dados não a confirmaram.

Onde o modelo erra, e por que isso é útil

Onde o erro cai, por faixa de erro absoluto



Sete em cada dez corridas ficam dentro da tolerância; a cauda acima de 10 °C responde por 12,9%.

Dizer que 72% das corridas ficam dentro da tolerância deixa 28% de fora, e errar 7 °C é diferente de errar 25 °C. Por isso quebrei o erro em faixas:

Faixa de erro	% das corridas de teste
até 3 °C	38,5%
3 a 6,8 °C	33,6%
6,8 a 10 °C	15,0%
10 a 20 °C	10,9%
acima de 20 °C	2,0%

O erro mediano é de 3,97 °C, o percentil 90 fica em 11,13 °C e o máximo em 30,10 °C.

A cauda é o que limita o uso. Cerca de uma corrida em cada oito, 12,9%, erra mais de 10 °C, e nessas a estimativa não substitui a medição. A pergunta prática é se dá para reconhecer essas corridas antes de rodá-las, e a resposta é sim:

	Corridas com erro > 10 °C	Demais	Diferença
temperatura inicial	1.596,1 °C	1.586,3 °C	+0,6%
energia total	0,26	0,19	+38,7%
duração do arco	36,8 min	28,9 min	+27,5%
potência ativa somada	3,70	2,98	+24,3%


As corridas ruins não se distinguem pela temperatura de entrada, que é praticamente igual à das demais. Elas se distinguem pelo volume de tratamento, e são as corridas longas e pesadas.

A leitura física é direta. Quanto mais longo o tratamento, mais tempo o banho troca calor com o refratário, com o ambiente e com as adições, e mais o resultado depende de fatores que não estão nos dados. O modelo é confiável no regime normal de operação e perde precisão exatamente onde o processo se afasta dele.

A consequência prática é o motivo de eu ter feito esta análise. O que separa as corridas ruins não é a temperatura de entrada, que ninguém escolhe, e sim o volume de tratamento, que é decidido antes de a corrida começar. Um plano que prevê muita energia e arco longo já sinaliza que ali a estimativa merece confirmação por medição.

Registro o limite dessa leitura. As diferenças acima estão medidas sobre energia e arco realizados, porque é o que os arquivos trazem. Transpor a regra para o plano supõe que o planejado se aproxima do executado, o que é razoável para dimensionamento mas não consigo verificar com estes dados.

Estimativa de impacto no negócio



A temperatura de entrada quase não distingue as corridas ruins; o volume de tratamento sim, e ele é decidido antes da corrida.

A coluna **Active power** não tem unidade documentada. Tentei calibrá-la pela física, comparando a energia registrada com a elevação de temperatura obtida, e a massa implicada não bate com a capacidade de 100 t informada sob nenhuma hipótese razoável de rendimento. Isso não invalida o modelo, porque ele aprende a relação entre a grandeza registrada e a temperatura seja qual for a escala dela, mas invalida qualquer conversão direta para megawatt-hora ou para reais.

Apresento então o impacto em três camadas, da mais firme para a mais dependente de informação externa: a grandeza física adimensional, que os dados sustentam por inteiro; a tradução para unidades operacionais que a planta reconhece; e a fórmula pronta para a conversão financeira, faltando um único parâmetro que só a planta tem.

Mecanismo da redução

Sem modelo, a incerteza sobre em que temperatura a corrida vai terminar é de 10,42 °C. Com o modelo, é de 5,22 °C. A margem de segurança térmica pode encolher em até 5,20 °C, e essa é a grandeza que o projeto entrega.

Converter graus em energia exige saber quanto a planta gasta por grau na margem, e não em média, porque são coisas diferentes. A energia de uma corrida paga duas contas ao mesmo tempo: elevar a temperatura do banho e repor o calor que ele perde para o refratário, para o ambiente e para as adições enquanto é tratado. A segunda parcela não desaparece quando se mira dois graus mais baixo. Dividir energia total por elevação obtida misturaria as duas contas e superestimaria a economia.

Separei-as regredindo a energia de cada corrida contra a elevação obtida e a duração do tratamento. A elevação responde por 0,00429 unidades de energia por grau, e a duração por 0,00439 unidades por minuto, com R² de 0,64. É o primeiro coeficiente que interessa aqui, porque é ele que mede o que se deixa de gastar ao mirar mais baixo:

Cenário	Margem reduzida	Energia poupada por corrida	% da energia de arco	Ciclos evitados
Conservador, captura 1/4 da margem	1,30 °C	0,0056	2,8%	0,13
Central, captura metade	2,60 °C	0,0112	5,6%	0,26
Teto, captura a margem inteira	5,20 °C	0,0223	11,3%	0,52

A hipótese que separa os cenários é quanto da margem de segurança a operação de fato consegue liberar. O teto supõe que hoje se sobreaquece exatamente o equivalente à incerteza, o que é agressivo, porque parte da margem existente responde a fatores que o modelo não elimina. Considero o cenário conservador o piso defensável e o central a expectativa realista.

Duas ressalvas sobre a estimativa do coeficiente. Ela é observacional: a energia aplicada causa a elevação e a duração é escolhida pelo operador, de modo que o número não é uma medida causal limpa. E ela não é constante ao longo da faixa, variando por fator de 2,7 entre as corridas que menos e as que mais aquecem, o que significa que a tabela vale para o regime médio de operação e perde validade nos extremos.

Impacto em unidades operacionais

Um ciclo de aquecimento consome em média 0,0428 unidades de energia. Nessa escala, o cenário conservador equivale a deixar de aplicar 0,13 ciclo por corrida, cerca de 1.280 ciclos por ano no ritmo de 9.850 corridas anuais. O cenário central equivale a 0,26 ciclo por corrida, cerca de 2.570 ciclos por ano, ou 5,6% de toda a energia de arco da planta.

Há um efeito paralelo que não entra nessa conta e é mais fácil de auditar, que são as medições de temperatura. A planta faz cerca de 40 mil por ano, cada uma consumindo um sensor descartável e interrompendo o processo. Um modelo que acerta dentro de 3 °C em 38,5% das corridas e dentro de 6,8 °C em 72% permite reduzir a frequência de medição de confirmação nas corridas do regime normal, mantendo-a integral nas 13% de cauda que a regra da seção anterior identifica de antemão.

A conversão financeira

Falta um único número, e ele não está nos dados:

```
Economia anual (R$) = 9.850 corridas × 0,0056 a 0,0112 unidades de energia por corrida  
× [ R$ por unidade de "Active power" ]
```

Traduzindo: a economia anual fica entre 55 e 110 unidades de energia, na escala em que a coluna **Active power** é registrada. Assim que a planta informar o que essa coluna mede, e o custo do megawatt-hora que ela pratica, a conta fecha em reais em uma linha.

Registro isso como pergunta a fazer, não como número a estimar. Chutar um fator de conversão produziria um valor bonito e indefensável.

Efeitos não energéticos


Há três efeitos que vale citar sem quantificar, porque quantificá-los exigiria dados que não estão aqui.

Deixar de aplicar de 0,13 a 0,26 ciclo por corrida libera capacidade do forno-panela. Se o forno for gargalo da linha, esse efeito pode superar o de energia. Se não for, ele não se materializa. Depende do arranjo da planta, que eu não conheço.

Reduzir a variabilidade da temperatura de entrega também deve reduzir a incidência de corridas fora da faixa de lingotamento, e portanto o retrabalho. Não consigo medir isso, porque os dados não trazem descarte nem qualquer indicador de qualidade.

Menos tempo de arco significa ainda menos consumo de eletrodo de grafite e menos agressão térmica ao revestimento refratário. O efeito vai na mesma direção da economia de energia, mas não tenho base nos dados para dimensioná-lo.

O que o modelo não sabe



Cenários de economia conforme quanto da margem de segurança a operação consiga liberar.

Entrego esta seção junto com o resultado porque um MAE dentro da meta é fácil de ler como problema resolvido, e não é o caso.

Começo pelo que é o inverso dos demais: em parte das corridas o modelo sabe demais. As variáveis de processo agregam a corrida inteira, mas nem sempre a última medição de temperatura é o último evento. Em 135 corridas, 5,5% do total, há aquecimento ou adição posteriores ao instante do alvo. Nessas, a energia somada carrega informação que ainda não existia quando a previsão seria feita. O MAE de 5,22 °C está provavelmente um pouco otimista por causa disso. O caminho correto é fixar o instante da previsão e agregar apenas o que ocorreu antes dele, e é o primeiro item que eu refaria.

O modelo não vê a composição química da corrida. Ligas diferentes têm calor específico diferente, e nada nos sete arquivos identifica qual liga está sendo produzida. Parte do erro residual quase certamente vem daí, e nenhum ajuste de hiperparâmetro alcança essa informação.

O modelo não vê o estado do refratário, a temperatura ambiente, o desgaste dos eletrodos nem a panela específica de cada corrida. A única proxy disponível foi testada e não funcionou.

O período coberto é de três meses. Não encontrei deriva dentro dessa janela, mas três meses não garantem estabilidade ao longo de um ano.

O formato de gravação mudou em 06/08/2019. Se ele continuar como ficou, dados novos chegam com uma única medição por corrida e não servem nem para treinar nem para validar o modelo.

Conclusões e recomendações

O que está entregue é um modelo que prevê a temperatura final do banho com erro médio de 5,22 °C, contra 10,42 °C de não ter modelo nenhum. A meta de 6,8 °C foi atingida com folga, 72% das corridas ficam dentro da tolerância, e a avaliação foi feita em corridas posteriores no tempo que o modelo nunca viu. Junto com ele vai uma regra que diz onde confiar nele e onde não confiar.

Deixo cinco recomendações, em ordem de retorno sobre esforço.

A primeira é adotar o modelo com regra de uso diferenciada, e não como número único. Nas corridas do regime normal, com plano de tratamento dentro da faixa usual de energia e arco, a previsão dimensiona o aquecimento e reduz a medição de confirmação. Nas corridas de tratamento longo e pesado, que os dados mostram serem cerca de 13% e que são identificáveis pelo plano, o modelo entra como orientação e a medição continua obrigatória. É a recomendação de maior valor imediato e não exige nenhum dado novo.

A segunda é informar o que a coluna `Active power` mede. É a única pendência entre a economia física já demonstrada e a economia em reais. Uma resposta da engenharia da planta resolve, e sem ela nenhuma estimativa financeira deste projeto se sustenta.

A terceira é restabelecer o registro de múltiplas medições de temperatura por corrida. O protocolo mudou em 06/08/2019 e, se permanecer assim, o modelo não pode ser retreinado nem revalidado com dados novos. É decisão da fábrica, não do modelo, e sem ela o projeto tem prazo de validade.

A quarta é refazer o recorte temporal dos atributos antes de tratar 5,22 °C como número final. Agregaria apenas operações anteriores ao instante da previsão e mediria o resultado em um bloco de tempo ainda não utilizado, porque este conjunto de teste também serviu para escolher entre as quatro famílias de modelo, de modo que o número atual tem um grau a menos de independência do que o ideal.

A quinta é registrar a liga produzida em cada corrida. É a informação ausente com maior potencial de reduzir o erro residual. Não altera nada no que já foi entregue, mas define o teto de uma versão futura.

Fecho com uma ressalva. O objetivo que declarei na Etapa 1, dimensionar o aquecimento em vez de buscá-lo por tentativa e erro, é alcançável com o que está aqui, desde que o modelo seja lido como comparação entre planos de tratamento e não como previsão passiva de uma corrida parada na entrada. É essa leitura condicional que transforma uma estimativa de temperatura em decisão de quanta energia aplicar, e é dela que vem a economia.